



---

Universidade Federal de Viçosa

---

**Universidade Federal de Viçosa**  
**Campus Florestal - Ciência da Computação**

**CCF 480 - META HEURÍSTICAS**

Aryel Penido - 3500

Taianne Motta - 2679

## **Trabalho prático 2:**

### **Algoritmo genético**

**Florestal**

**2021**

## Introdução

Esse trabalho teve como objetivo a implementação de um algoritmo genético. O algoritmo deveria ser implementados para Minimizar as seguintes funções objetivo:

1.  $G6(x) = (x_1 - 10)^3 + (x - 20)^2$  para as seguintes restrições de domínio
  - a.  $13 \leq x_1 \leq 100$
  - b.  $0 \leq x_2 \leq 100$

E sujeita às seguintes restrições :

- c.  $g_1(x) = -(x_1 - 5)^2 - (x_2 - 5)^2 + 100 \leq 0$
- d.  $g_2(x) = (x_1 - 6)^2 + (x_2 - 5)^2 + 82.81 \leq 0$

As configurações utilizadas foram:

Configuração A		
nVariaveis	tamanho população	número iterações
2	100	10

Configuração B		
nVariaveis	tamanho população	número iterações
2	1000	100

## Implementação

O código para os algoritmos do trabalho foram desenvolvidos em python com a ajuda de um tutorial que está referenciado ao final deste documento. O algoritmo genético foi implementado com representação real, o *método de cruzamento* foi o aritmético, o de *seleção* foi a proporcional ao fitness (aqui a função fitness é a função objetivo) e o *critério de parada* foi o número de iterações definidos nas tabelas acima. A penalidade escolhida para as restrições foi a de morte, os indivíduos que não fossem válidos para  $g_1$  e  $g_2$  eram descartados. O Arquivo AGValidacao tem uma implementação do algoritmo ajustado para função  $x^2$  com limites entre 0 e 10. O resultado esperado é 0 ou algo muito próximo de 0, o resultado de uma execução é mostrado abaixo.

```
#####
geração: 0
melhor solucao intermediaria: struct({'x1': 0.01047905253724335, 'sol': 0.00010981054207830628})
#####
geração: 1
melhor solucao intermediaria: struct({'x1': 0.01047905253724335, 'sol': 0.00010981054207830628})
#####
geração: 2
melhor solucao intermediaria: struct({'x1': 0.01047905253724335, 'sol': 0.00010981054207830628})
#####
geração: 3
melhor solucao intermediaria: struct({'x1': 0.01047905253724335, 'sol': 0.00010981054207830628})
#####
geração: 4
melhor solucao intermediaria: struct({'x1': 0.01047905253724335, 'sol': 0.00010981054207830628})
#####
geração: 5
melhor solucao intermediaria: struct({'x1': 0.01047905253724335, 'sol': 0.00010981054207830628})
#####
geração: 6
melhor solucao intermediaria: struct({'x1': 0.01047905253724335, 'sol': 0.00010981054207830628})
#####
geração: 7
melhor solucao intermediaria: struct({'x1': 0.0023665024387740097, 'sol': 5.600333792723336e-06})
#####
geração: 8
melhor solucao intermediaria: struct({'x1': 0.0023665024387740097, 'sol': 5.600333792723336e-06})
#####
geração: 9
melhor solucao intermediaria: struct({'x1': 0.0023665024387740097, 'sol': 5.600333792723336e-06})
melhor solução: struct({'x1': 0.0013302026302320913, 'sol': 1.7694390374763739e-06})
```

### execução para $x^2$

O problema e os parâmetros foram definidos utilizando a biblioteca structure do yppstruct.

```
#problema
problema = structure()
problema.funcao = G6
problema.nVariaveis = 2
problema.limitInf = [13,0]
problema.limitSup = [100,100]

#parametros
params = structure()
params.maxIt = 100
params.npop = 1000 #aumentar depois
params.sigma = 0.1

#indivuido
indivuido = structure()
indivuido.x1 = None
indivuido.x2 = None
indivuido.sol = None
```

### estrutura de indivíduos

O cruzamento foi feito utilizando a fórmula  $Y = up1 + (1 - u) * p2$  onde  $p1$  e  $p2$  são os indivíduos pais.

```
def cruzamento(p1x1, p1x2, p2x1, p2x2):
    f1.x1 = p1x1
    f1.x2 = p1x2
    f2.x1 = p2x1
    f2.x2 = p2x2
    alpha = np.random.uniform(0,1)

    f1.x1 = alpha*p1x1+(1-alpha)*p1x2
    f1.x2 = alpha*p1x2+(1-alpha)*p1x1

    f2.x1 = alpha*p2x1+(1-alpha)*p2x2
    f2.x2 = alpha*p2x2+(1-alpha)*p2x1
```

**cruzamento**

A mutação foi feita utilizando  $vk = \sigma(bk - ak)(2U(0,1) - 1)$

```
#mutacao
def mutacao(x):
    y = x.deepcopy()
    u = np.random.uniform(0,1)
    sigma = 0.1
    aux = y.x1
    aux2 = y.x2
    y.x1 = sigma*(problema.limitSup[0] - problema.limitInf[0])*((2*u) - 1)
    y.x1 = y.x1 + aux
    y.x2 = sigma*(problema.limitSup[1] - problema.limitInf[1])*((2*u) - 1)
    y.x2 = y.x2 + aux2
    return y
```

**mutação**

## Resultados

Para a configuração A e B os resultados encontrados estão descritos na tabela abaixo

Algoritmo	Mínimo	Máximo	Média	Desvio-padrão
AG configuração A	-7535.610848315226	3183.59879658167	-2305.2059551845846	2898.302943203686
AG configuração B	-7818.1681165828095	-4239.02343416096	-6395.040656411191	962.7966803229893

o menor valor encontrado nas 30 iterações para configuração A foi

G6 = -7535.610848315226 com  $x_1 = 17.032378903676694$  e

$x_2 = 0.09764882424958543$  durante a execução 25


o menor valor encontrado nas 30 iterações para configuração A foi

G6 = -7818.1681165828095 com  $x_1 = 15.569422475791814$  e


$x_2 = 0.007566977376638473$  durante a execução 23

## Gráficos com boxplot

Gráfico da Configuração A:



### Gráfico da Configuração B:



### Conclusão

Os resultados que encontramos mostram que aumentar o tamanho da população e o número de iterações faz com que a distribuição das soluções encontradas fique mais próxima, como mostra o desvio padrão menor em B. Além disso, os mínimos gerais também diminuíram, o que mostra que quanto maior a população alinhada a um número grande de iterações melhor é a solução encontrada.

### Referências

Genetic Algorithm in Python - Part A - Practical Genetic Algorithms Series *Youtube*. Disponível em: <<https://www.youtube.com/watch?v=PhJgktRB1AM>>. Acesso em: 24 de set. 202021. 0:42:39

Genetic Algorithm in Python - Part B - Practical Genetic Algorithms Series. *Youtube*. Disponível em: <<https://www.youtube.com/watch?v=gIlygj3UIBs&t=447s>>. Acesso em: 24 de set. 202021. 0:33:49